Detecção de Atividade Cerebral Prejudicial

Time

João Smolinski - Analista

Letícia Ruas - Cientista

Lívia Pereira - Engenheira

Problema

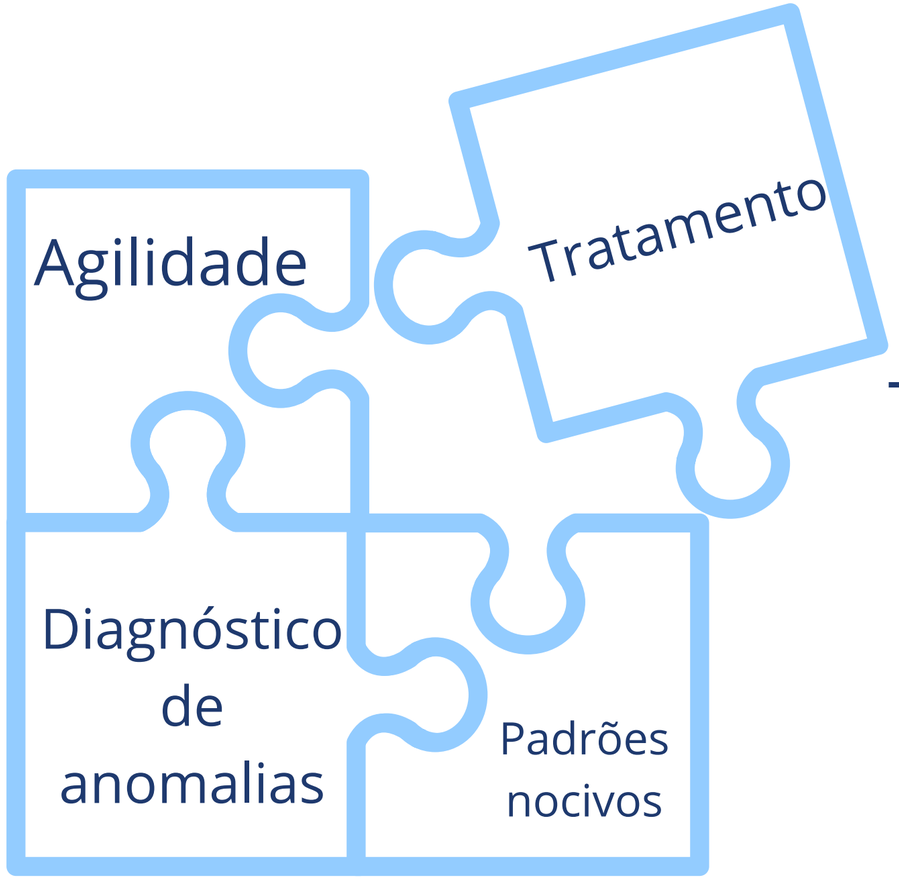

OBJETIVO

Desenvolver um sistema de apoio à decisão médica: um dashboard interativo impulsionado por modelo de previsão. Para essa sprint, entregar um MVP

Base de Dados e Tecnologias

Os dados são originários do Kaggle (competição HMS), compostos por espectrogramas médicos, que traduzem o sinal elétrico cerebral para uma matriz visual de frequência e tempo. O modelo busca prever seis colunas principais, que representam as classificações dadas por médicos reais (seizure_vote, lpd_vote, gpd_vote, lrda_vote, grda_vote, other_vote). Todo o ecossistema foi construído em Python, utilizando NumPy e Pandas para a extração de características, XGBoost para treinar um modelo preditivo robusto, e o Streamlit para o dashboard.

Uma história está pronta para entrar no Backlog da Sprint quando ela representa um passo essencial e insubstituível para que o MVP funcione de ponta a ponta (ou seja, cobre exclusivamente as etapas de preparar os dados, treinar um modelo de referência e entregar uma interface funcional ao usuário final) e pode ser concluída, testada e demonstrada dentro de uma única sprint.

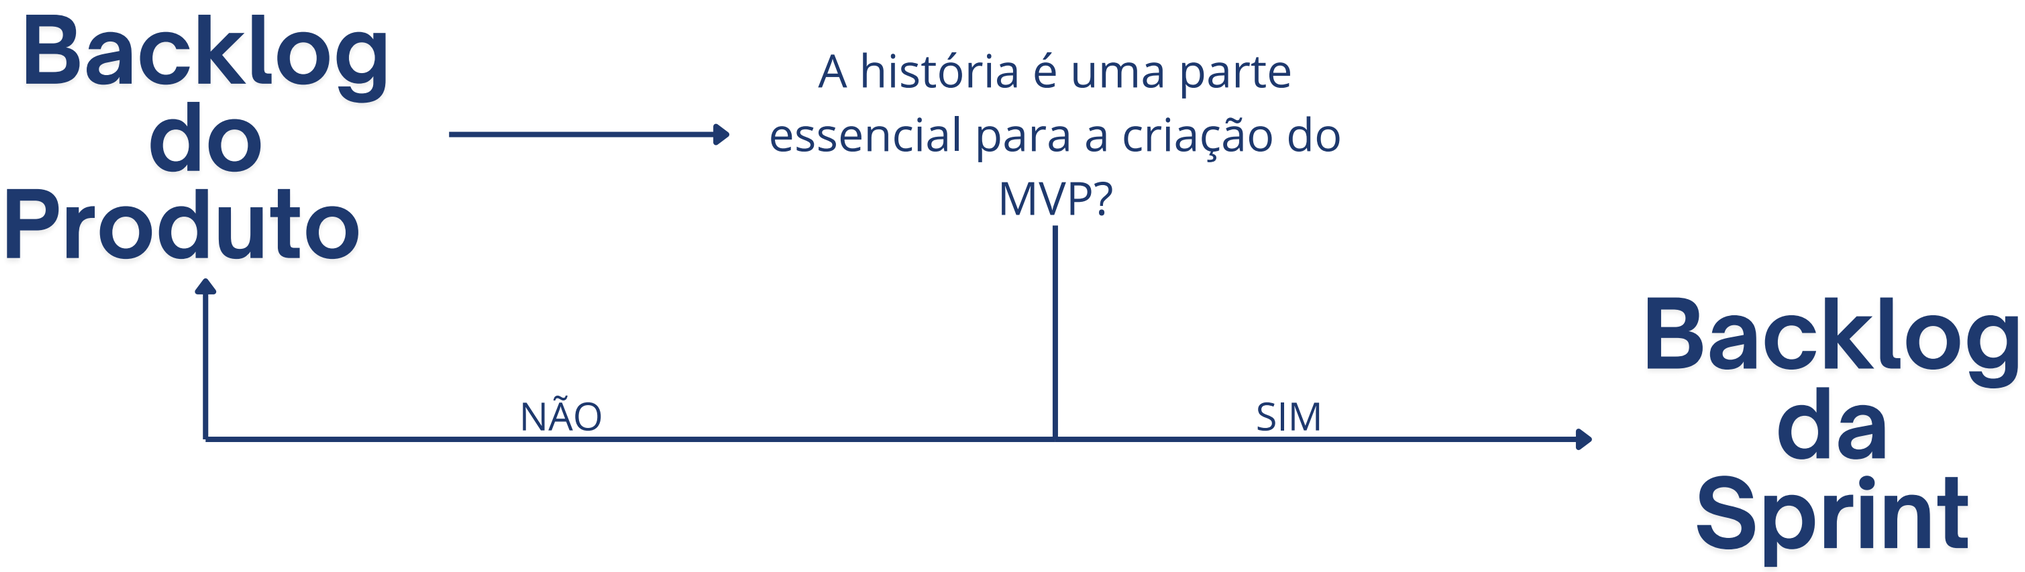

Sprint - Mínimo Produto Viável

Como engenheiro de dados gostaria de carregar, entender, fazer um tratamento inicial e mesclar os metadados (train.csv) com os arquivos .parquet para criar um dataset viável para o treinamento inicial do modelo.

Artefato

Notebook Python

Critério de Conclusão

O notebook deve carregar e mesclar o train.csv com os arquivos .parquet sem erros, tratando nulos, duplicatas e inconsistências, com o dataset final documentado e as decisões de tratamento explicadas em células de texto.

Sprint - Mínimo Produto Viável

Artefato

Notebook Python

Critério de Conclusão

O notebook deve gerar visualizações legíveis da distribuição das 6 colunas de Target, calcular ao menos uma métrica de discordância entre especialistas e concluir com uma interpretação textual das classes de maior incerteza.

Como Analista de Dados, quero explorar e visualizar a distribuição das 6 colunas de Target do train.csv, para entender quais geram maior incerteza, discordância e erro entre os próprios especialistas humanos.

Sprint - Mínimo Produto Viável

Como cientista de dados, eu quero treinar um modelo inicial capaz de processar os dados brutos, para que eu possa estabelecer uma métrica de referência de desempenho, realizando o processo de treino e teste.

Artefato

Notebook Python

Critério de Conclusão

O notebook deve treinar e avaliar um modelo baseline com divisão treino/teste reproduzível, exibindo as métricas de forma comparativa, registrando explicitamente o valor de referência e salvando o modelo treinado em arquivo.

Sprint - Mínimo Produto Viável

Artefato

Dashboard

Critério de Conclusão

O dashboard deve iniciar sem erros, aceitar upload de .npy, exibir as probabilidades das 6 classes e o espectrograma do paciente, permitir salvar e recuperar resultados por ID, converter .parquet para .npy e exibir corretamente o histórico com mapa de calor e distribuição de diagnósticos.

Como neurologista, gostaria de inserir dados (Espectograma) de um novo paciente no modelo e receber as probabilidades para cada classe de anomalia, para me auxiliar em um diagnóstico rápido

Backlog do Produto

1. Como Engenheira de Dados, quero construir um DataLoader que forneça os dados em lotes (batches) organizados, para otimizar o consumo de memória durante o treinamento.
2. Como Cientista de Dados, eu quero melhorar e desenvolver as estratégias de treino e teste do modelo, a fim de melhorar o desempenho das técnicas.
3. Como Cientista de Dados, eu quero registrar e plotar o histórico de treinamento do modelo a cada época, para que possa analisar visualmente a curva de aprendizado e identificar de forma rápida se o modelo está sofrendo de overfitting ou underfitting.
4. Como Médico Intensivista, quero visualizar em um dashboard simples o espectrograma do paciente junto com o alerta de risco gerado pelo modelo, para que eu possa intervir rapidamente em casos de parada cardíaca ou derrame.
5. Como Analista de Dados, quero mapear a quantidade de eeg_id e spectrogram_id únicos associados a cada patient_id, para entender a representatividade de cada paciente e analisar fenômenos relacionados a pacientes recorrentes
6. Como Neurologista, quero ter uma interface onde eu possa registrar o meu diagnóstico após analisar o exame e a predição do modelo, para ajudar a retroalimentar a base com novos votos médicos.

Estrutura do Pipeline

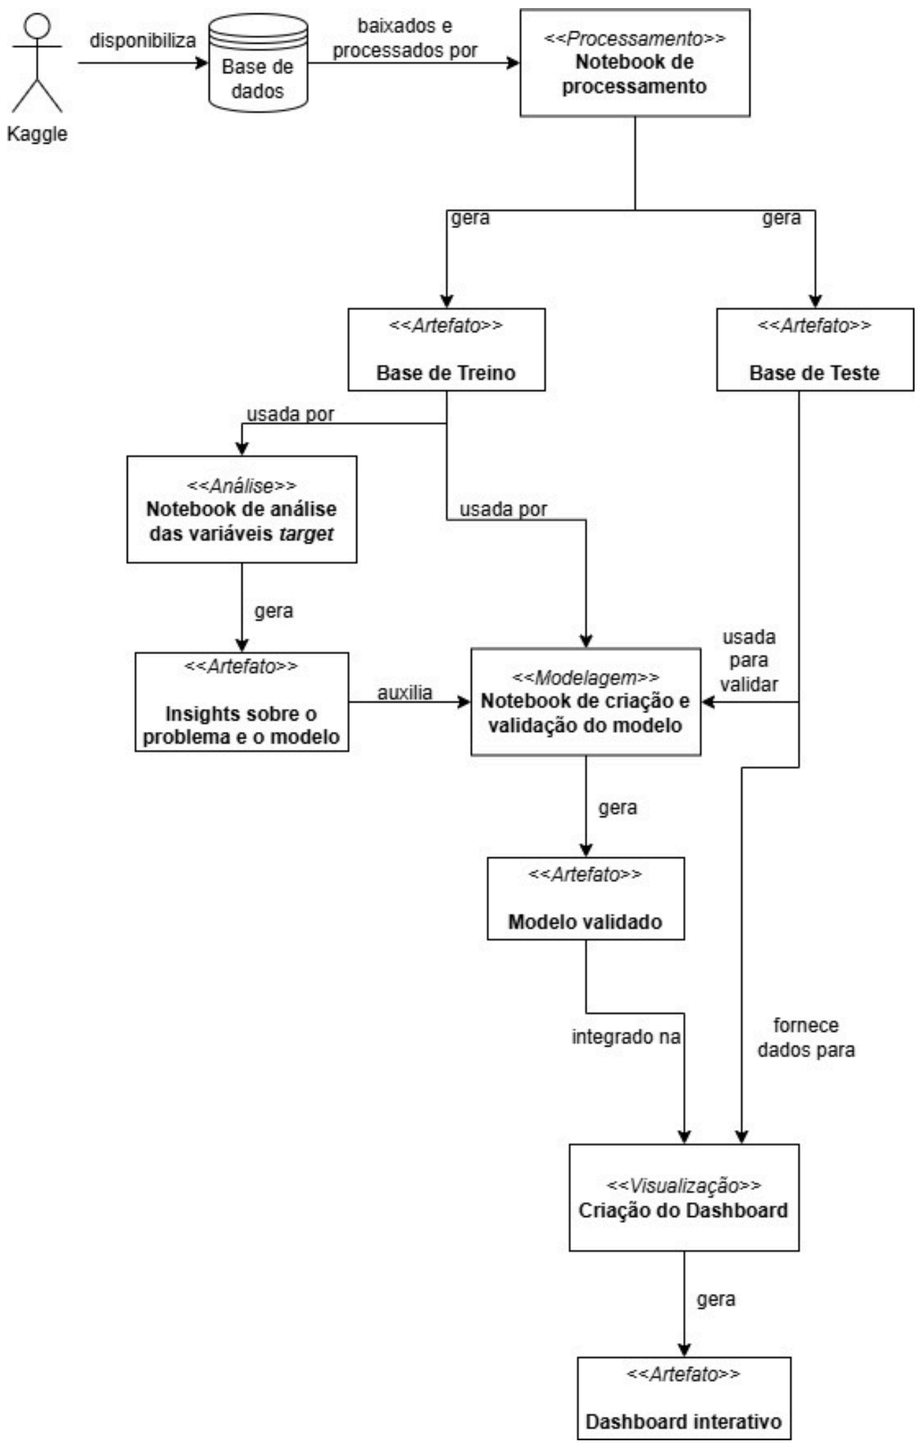

1. Limpeza e tratamento

Historia de usuário 1 - Engenheira de dados

- Entendimento da base: 106.800 linhas (recortes) referentes a 17.089 exames únicos com chaves de identificação
- Definição do MVP: Agrupamento por paciente e exame para selecionar apenas a primeira medição temporal de cada caso (evita pesos desproporcionais e acelera processamento)
- .parquet → .npy com tamanho fixo
- Separação em treino e teste por 80/20 estratificado por doença

2. Análise Exploratória

Historia de usuário 2 - Analista de dados

Objetivo: Compreender as variáveis ‘target’ (anomalias)

Qual variável ‘target’ gera mais incerteza até mesmo em especialistas humanos?

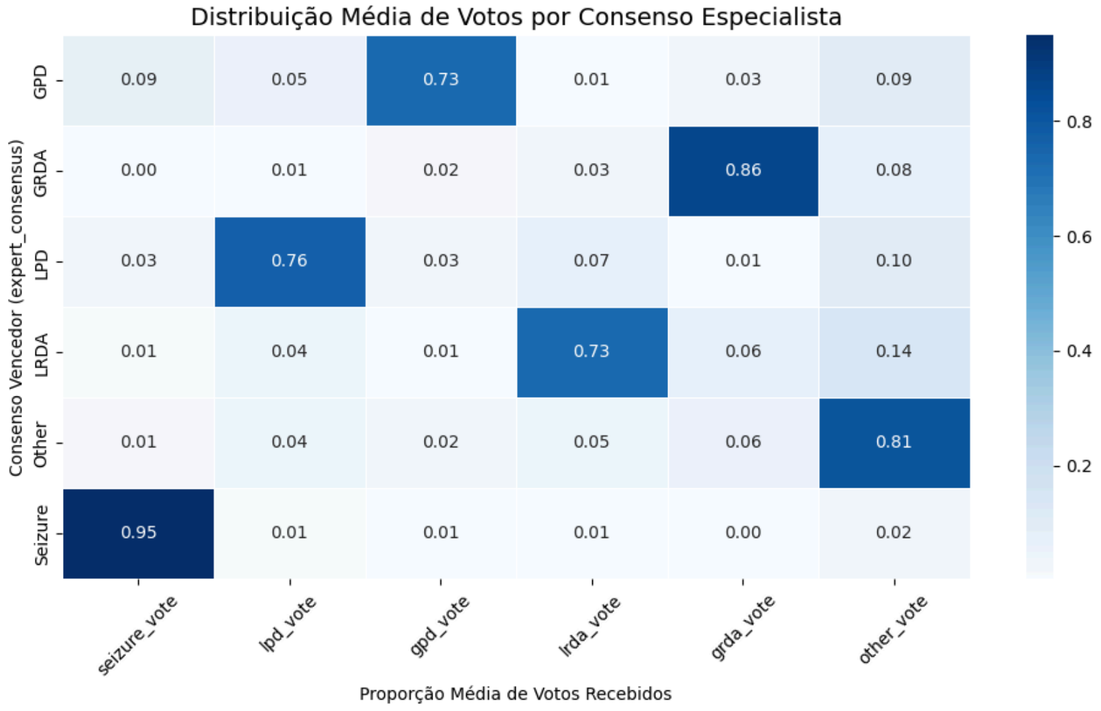

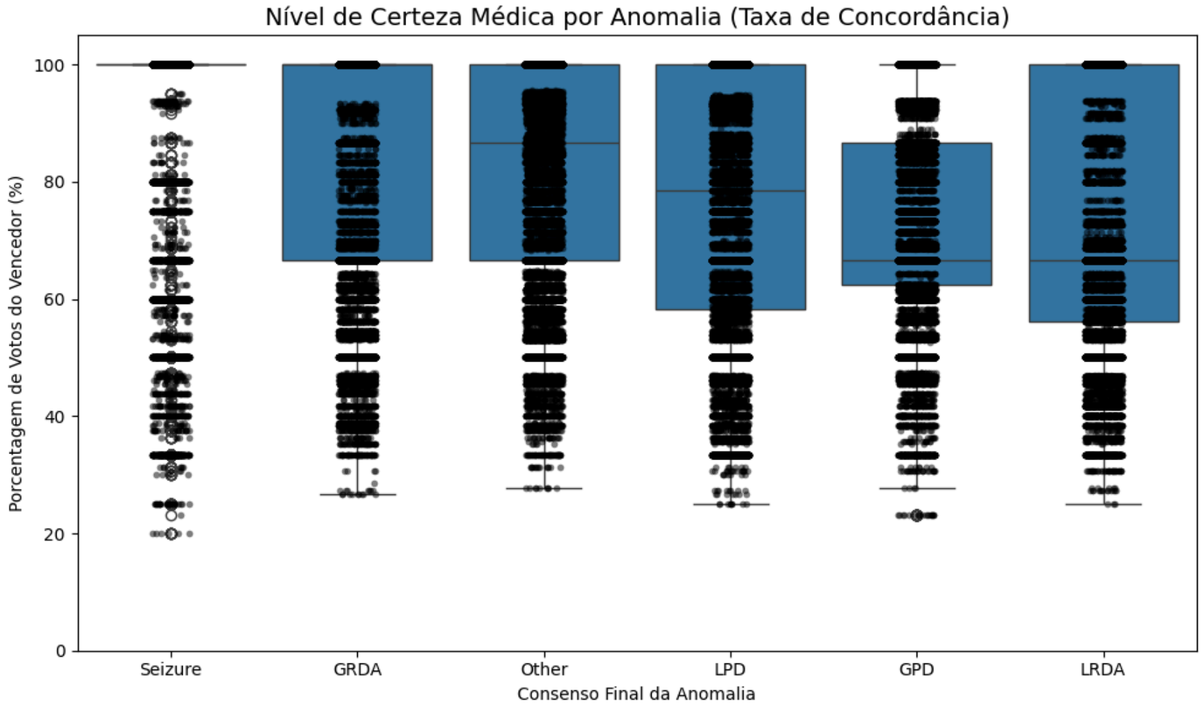

2. Análise Exploratória

Historia de usuário 2 - Analista de dados

Insights: Seizure (Convulsões) são quase unânimes para os neurologistas, com pouca divergência de votos.

LRD, LRDA e GPD têm uma maior incerteza com outros diagnósticos

É esperado que o modelo preveja melhor os casos de Seizure do que outros.

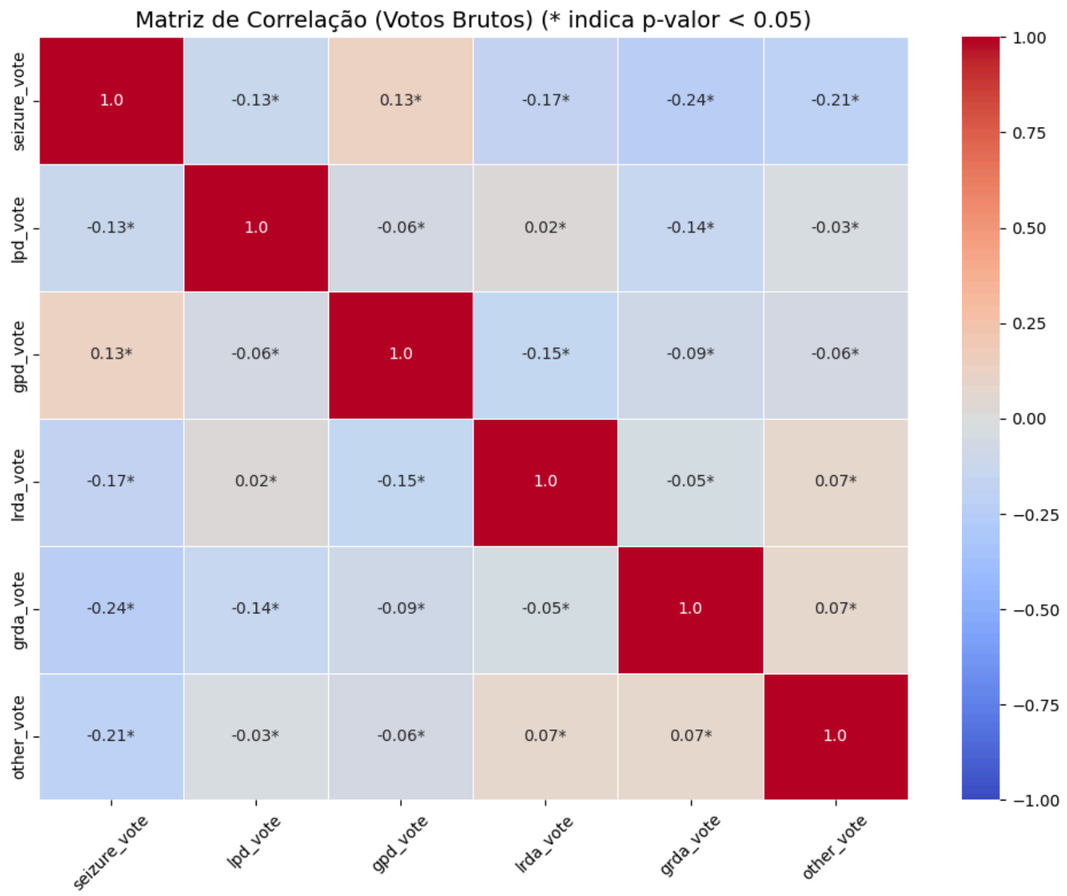

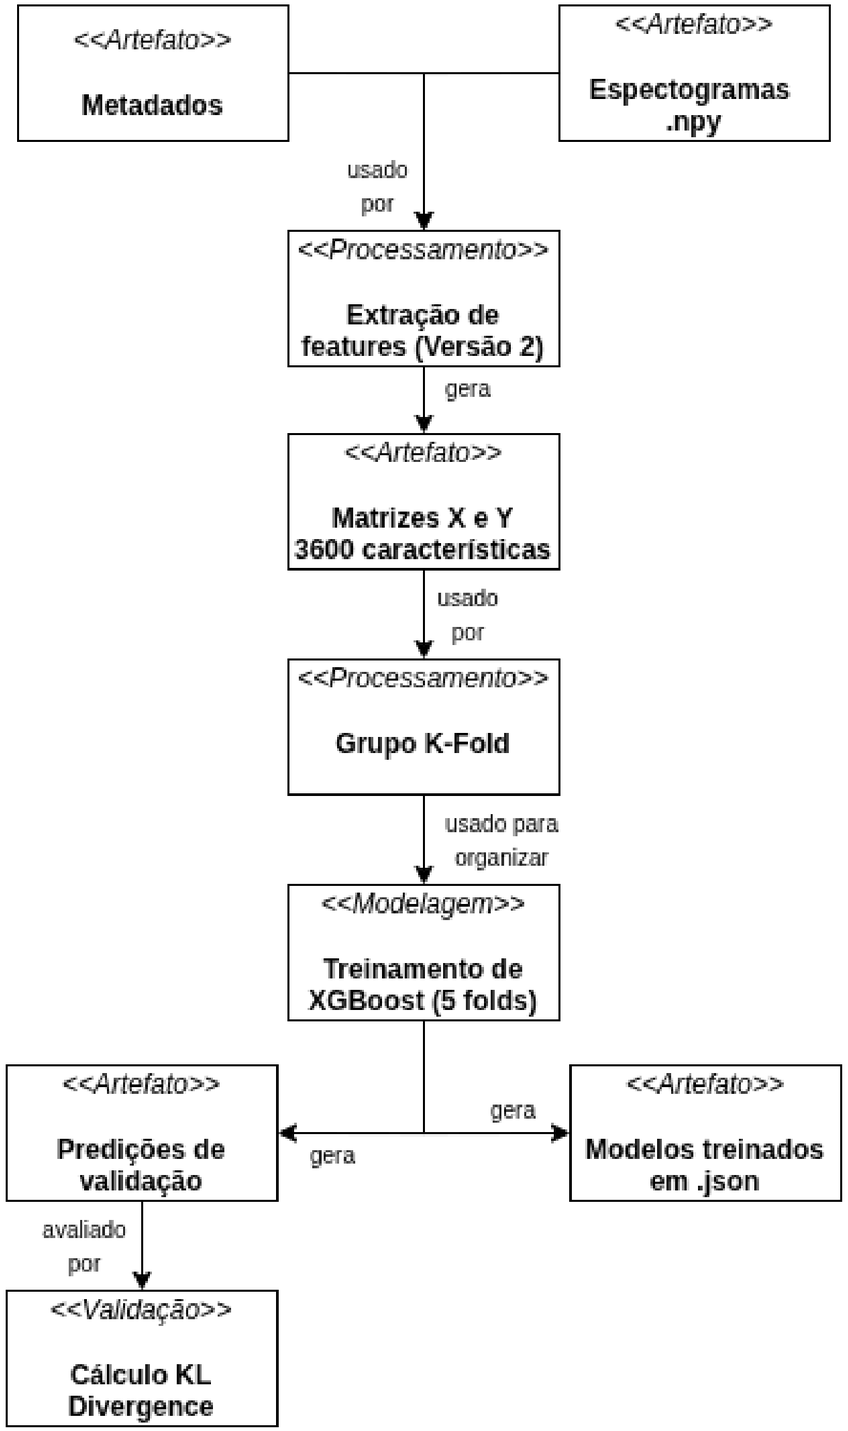

Criação do modelo

3. Criação do modelo

Historia de usuário 3 - Cientista de dados

- **Extração de Features:** Transformação dos espectrogramas em dados tabulares, calculando a média e o desvio padrão.

- **Validação Cruzada:** GroupKFold e Divisão dos dados em 5 partes.

- **Treinamento:** Configuração e treino de 5 modelos XGBoost focados em prever probabilidades.

3. Criação do modelo

Historia de usuário 3 - Cientista de dados

- **Avaliação:** Implementação da métrica KL DIVERGENCE para medir o erro.
- **Ensemble**: Predição do conjunto de teste final feita a partir da média dos 5 modelos.
- Construção de um pipeline completo que transformou dados complexos de ondas cerebrais em um sistema de diagnóstico validado e estável.

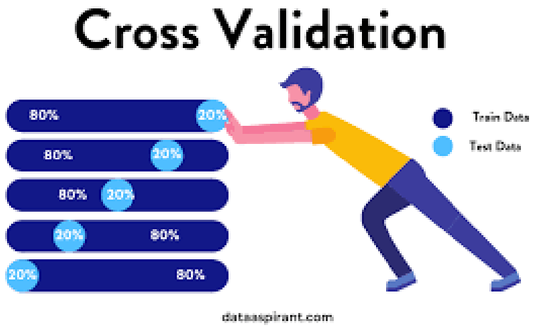

4. Criação do Dashboard

Historia de usuário 4 - Neurologista

- **Implementado por Engenheira de Dados e Analista de Dados**
- **Implementação:** O Dashboard foi implementado usando a biblioteca streamlit do python

- **Objetivo:** Construir uma interface que possa ser utilizada pelo agente 'Neurologista'

Tela 1: Diagnóstico auxiliado

Com base no modelo criado, o neurologista utiliza o arquivo do exame, em formato .npy, para obter o diagnóstico gerado.
A saída é a probabilidade de cada anomalia, calculada pelos modelos. Além disso, o neurologista pode conferir o espectrograma do exame e pode também salvar a saída.

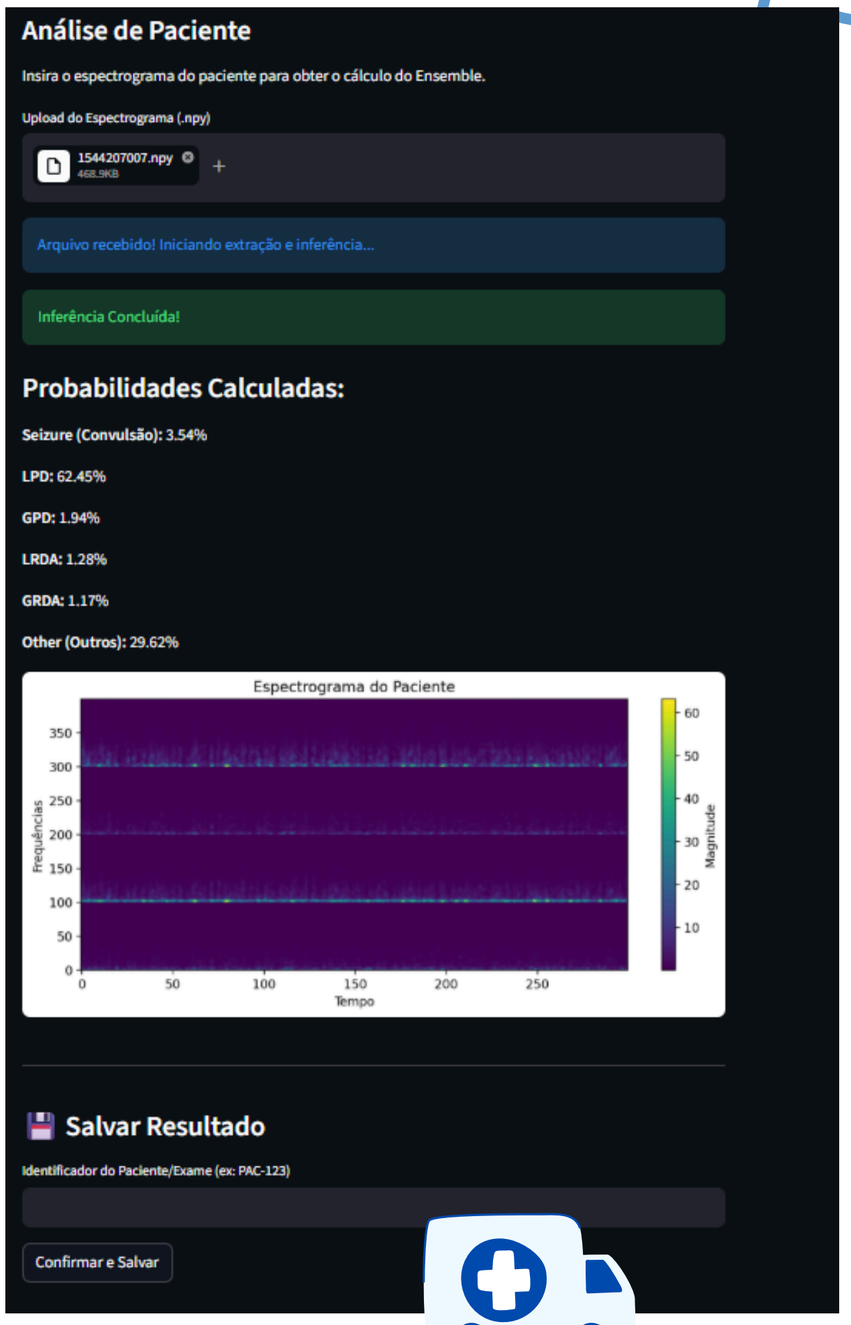

Tela 2: Conversão de arquivo

Nessa tela, o usuário pode converter um arquivo .parquet (formato original no qual os dados se encontravam) em um arquivo .npy, que é o formato utilizado para o cálculo das probabilidades

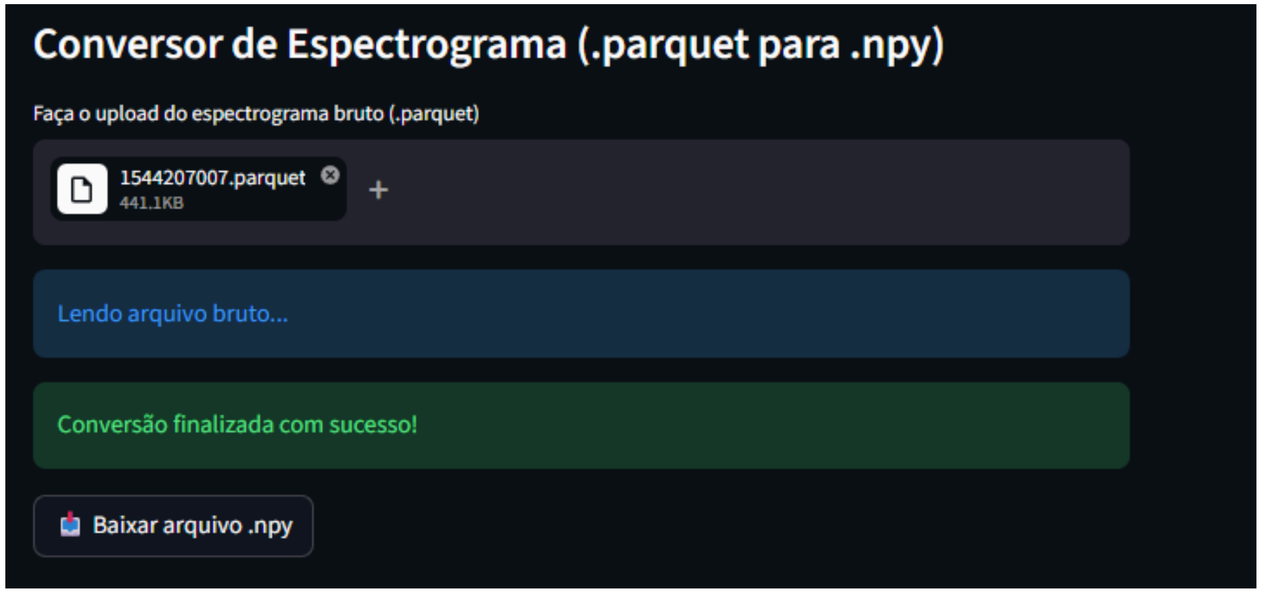

Tela 3: Pacientes e Exames salvos

Com base nos pacientes salvos na primeira aba, o usuário consegue ter uma visão geral dos dados (anomalias mais comuns e mapa de calor geral das probabilidades)

Além disso, consegue visualizar um detalhamento de cada exame, com as probabilidades exatas calculadas e o espectrograma

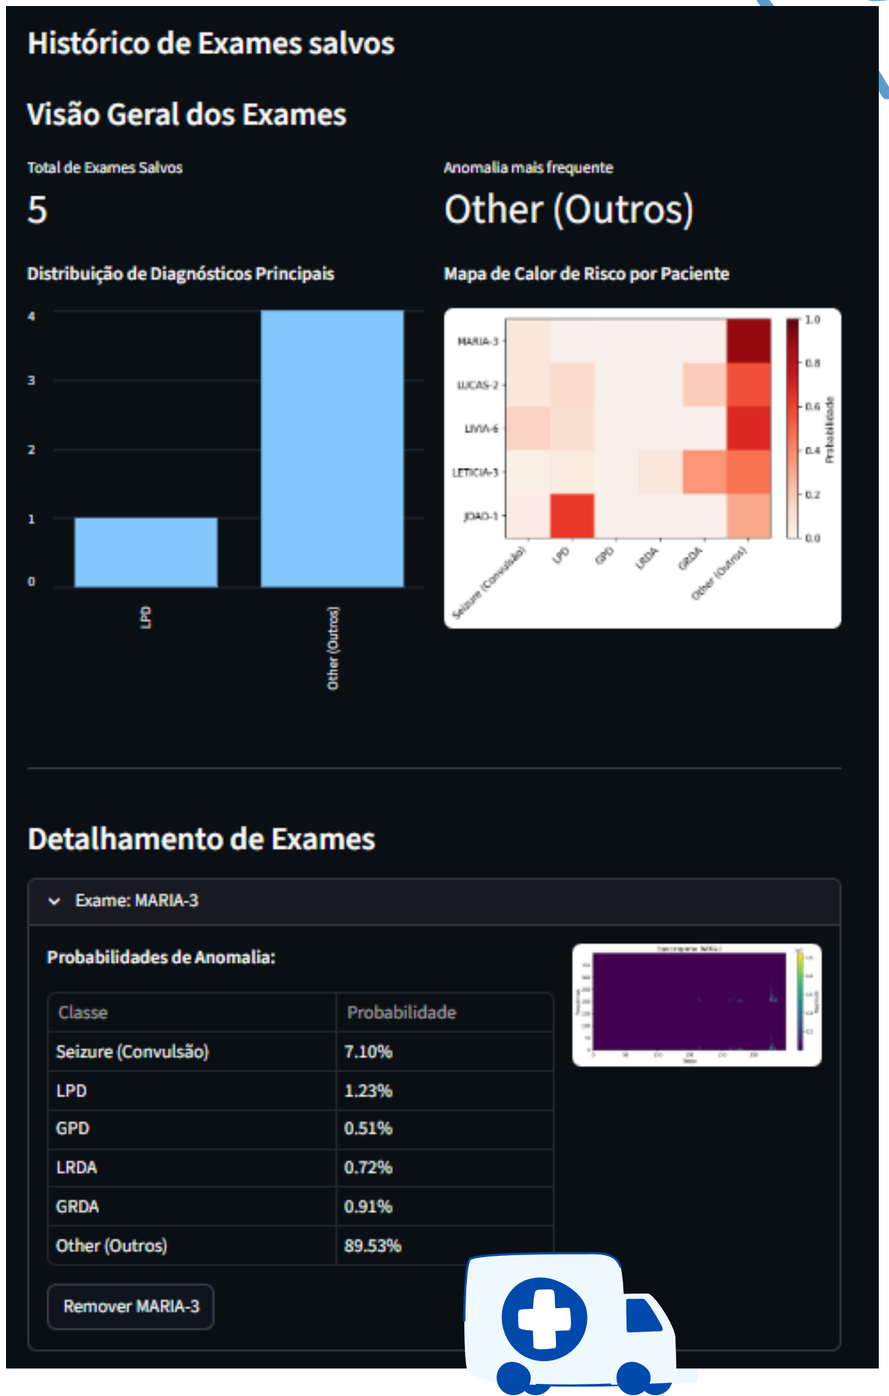

Dashboard em uso

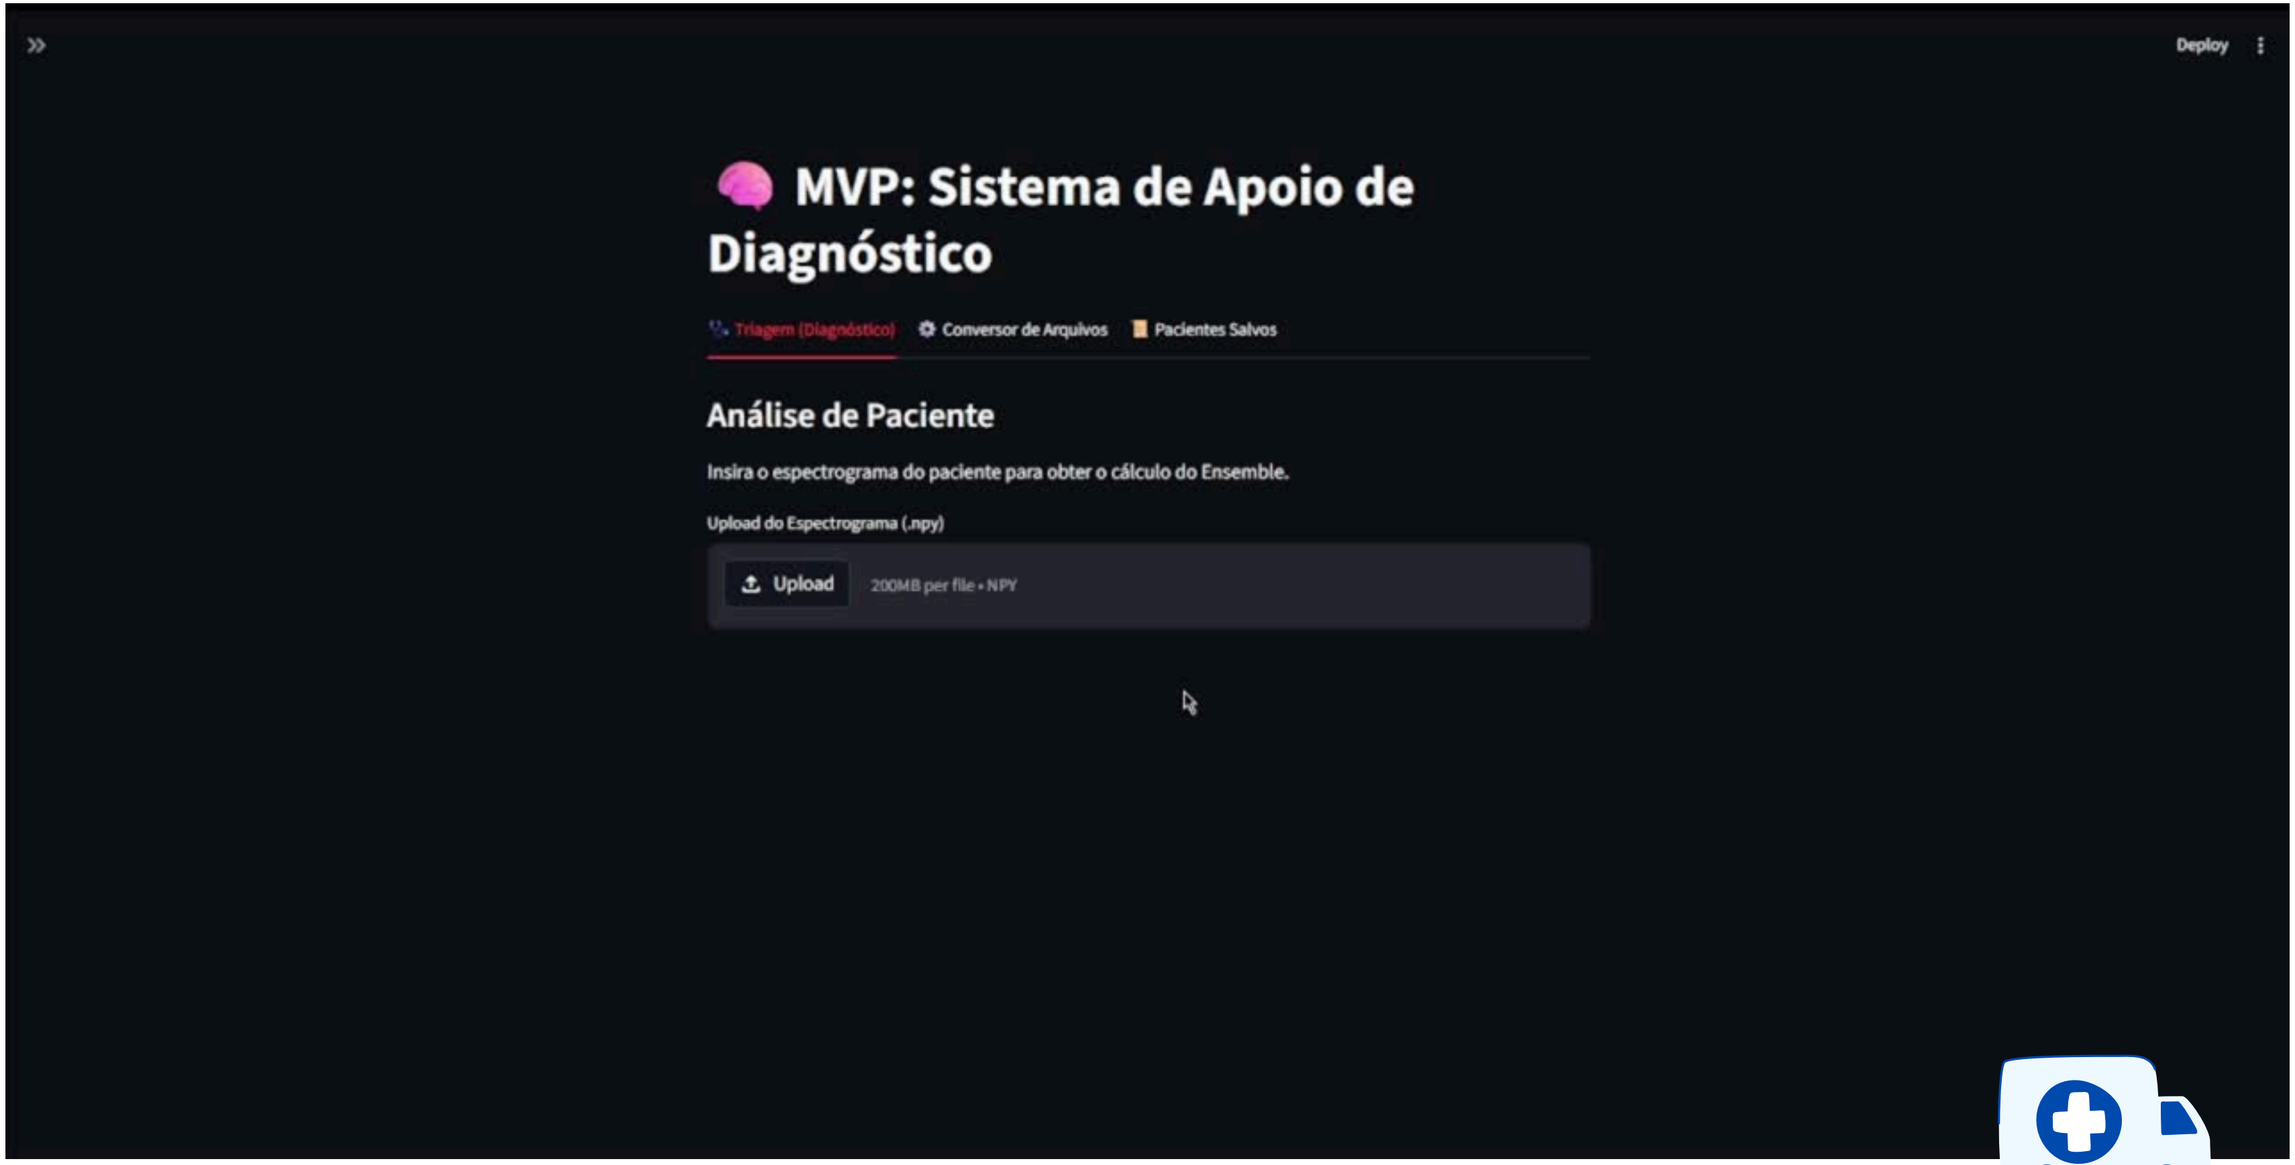

Retrospectiva

Pontos positivos

- **Divisão de tarefas**
- Gestão de tempo
- Comunicação
- Revisão de código

Pontos a melhorar

- Planejamento (DoD)
- Padronização

Perguntas

Agradecemos a atenção